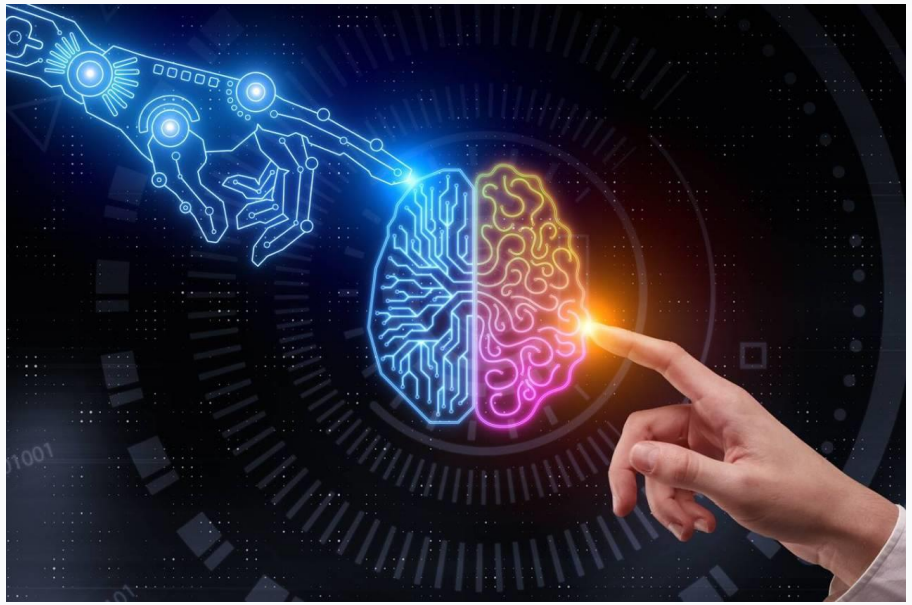

Inteligência Artificial

Machine Learning – Conceitos Introdutórios

Profº - Dr. Thales Levi Azevedo Valente

thales.l.a.valente@gmail.com.br

Governo Federal

Grupo da turma 2024.2

https://chat.whatsapp.com/JFB6CgOI7lMCoYmoIKEK62

Sejam Bem-vindos !

Os celulares devem ficar no silencioso ou desligados

Pode ser utilizado apenas em caso de emergência

Boa tarde/noite, por favor e com licença DEVEM ser usados

Educação é essencial

Machine Learning

Introdução

- **A aprendizagem de máquina é o estudo dos algoritmos de aprendizado.**
- **Diz-se que um programa de computador aprende com a experiência (E) em relação a uma classe de tarefas (T) e medida de desempenho (D) se seu desempenho nas tarefas, conforme medido por D , melhora com a experiência.**

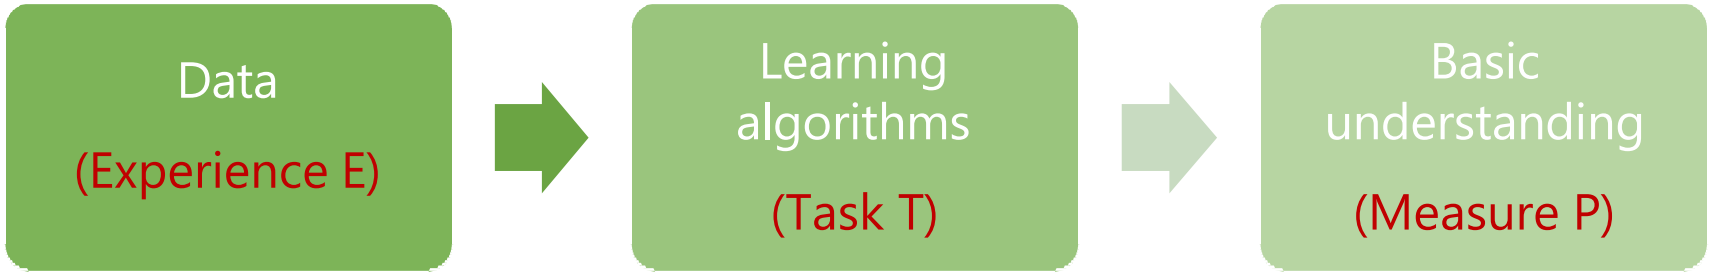

Machine Learning

Introdução

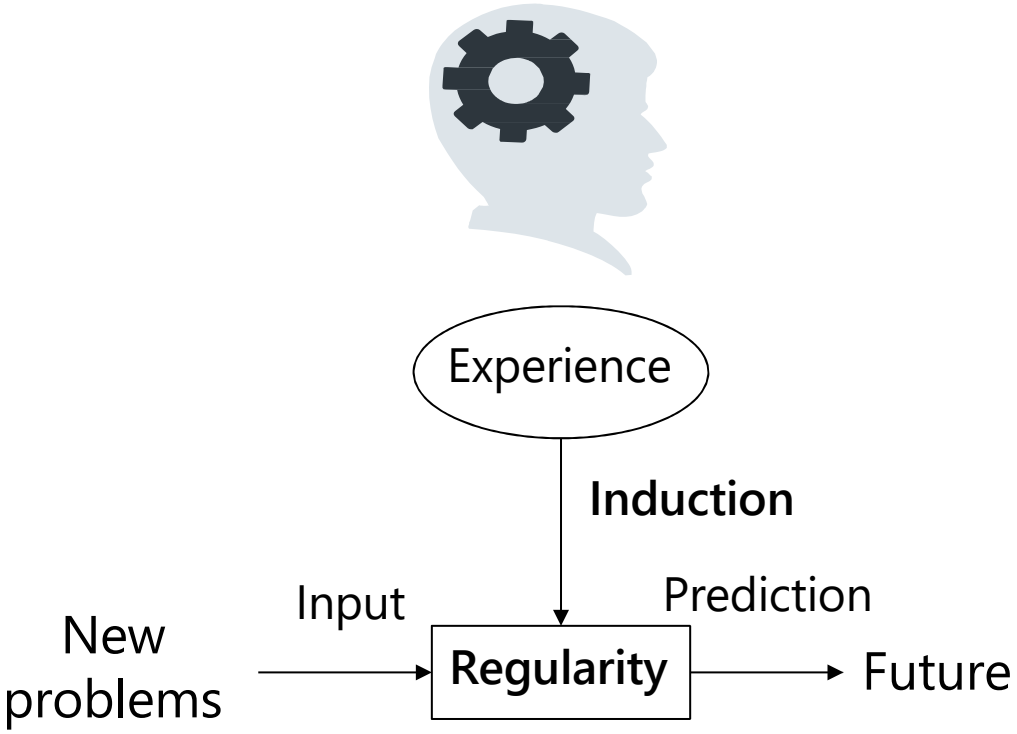

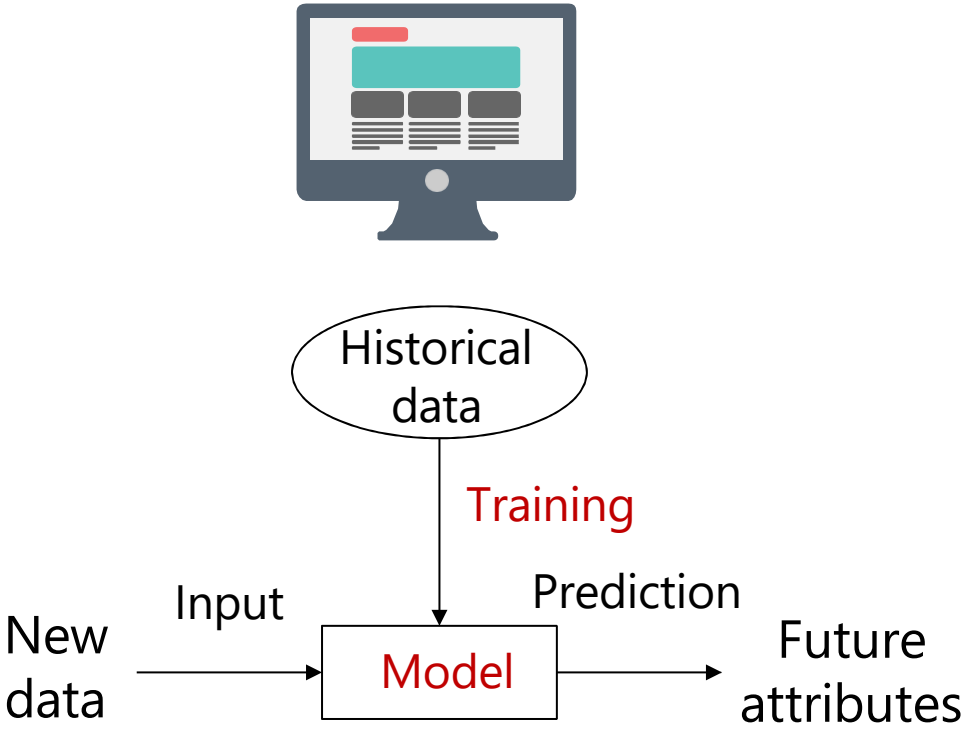

Machine Learning

Machine Learning vs Sistemas baseados em regras

Rule-based algorithms

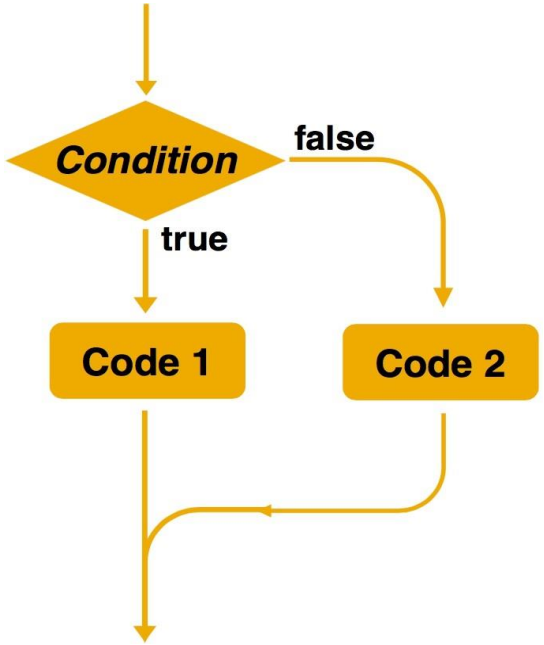

- Explicit programming is used to solve problems.
- Rules can be manually specified.

Machine learning

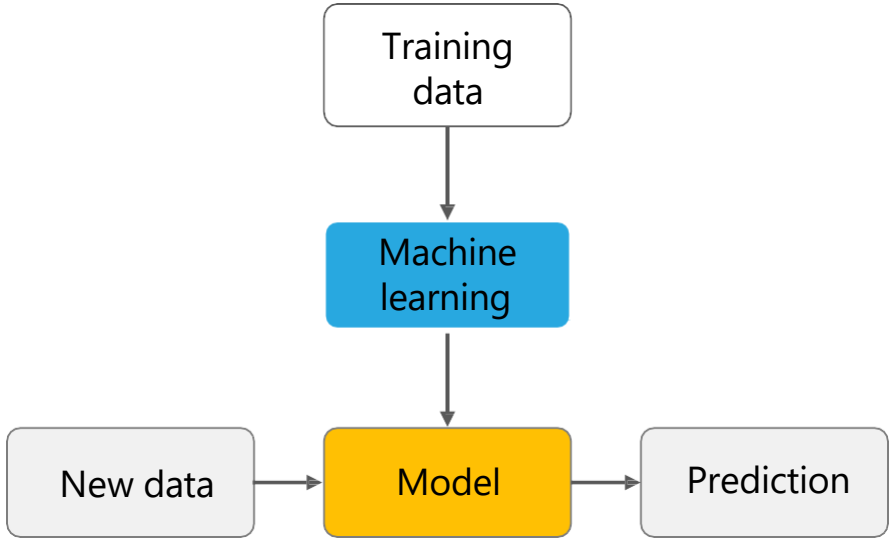

- Samples are used for training.
- The decision-making rules are complex or difficult to describe.
- Rules are automatically learned by machines.

Machine Learning

Cenários

- **A solução para um problema é complexa, ou o problema pode envolver uma grande quantidade de dados sem uma função de distribuição de dados clara.**

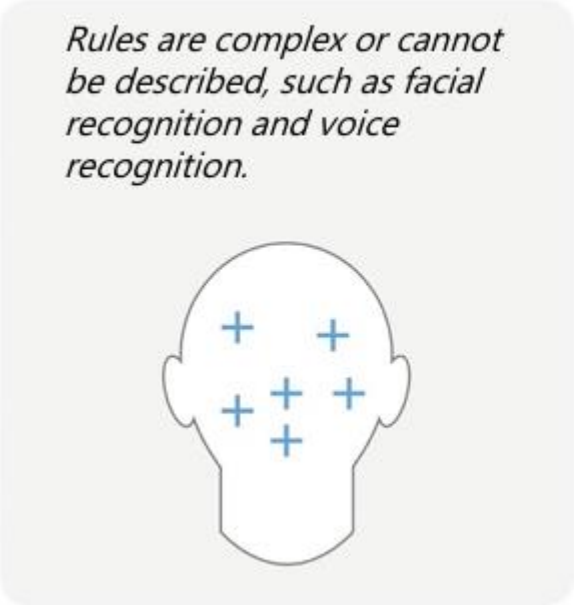

Machine Learning

Cenários

- **A solução para um problema é complexa, ou o problema pode envolver uma grande quantidade de dados sem uma função de distribuição de dados clara.**

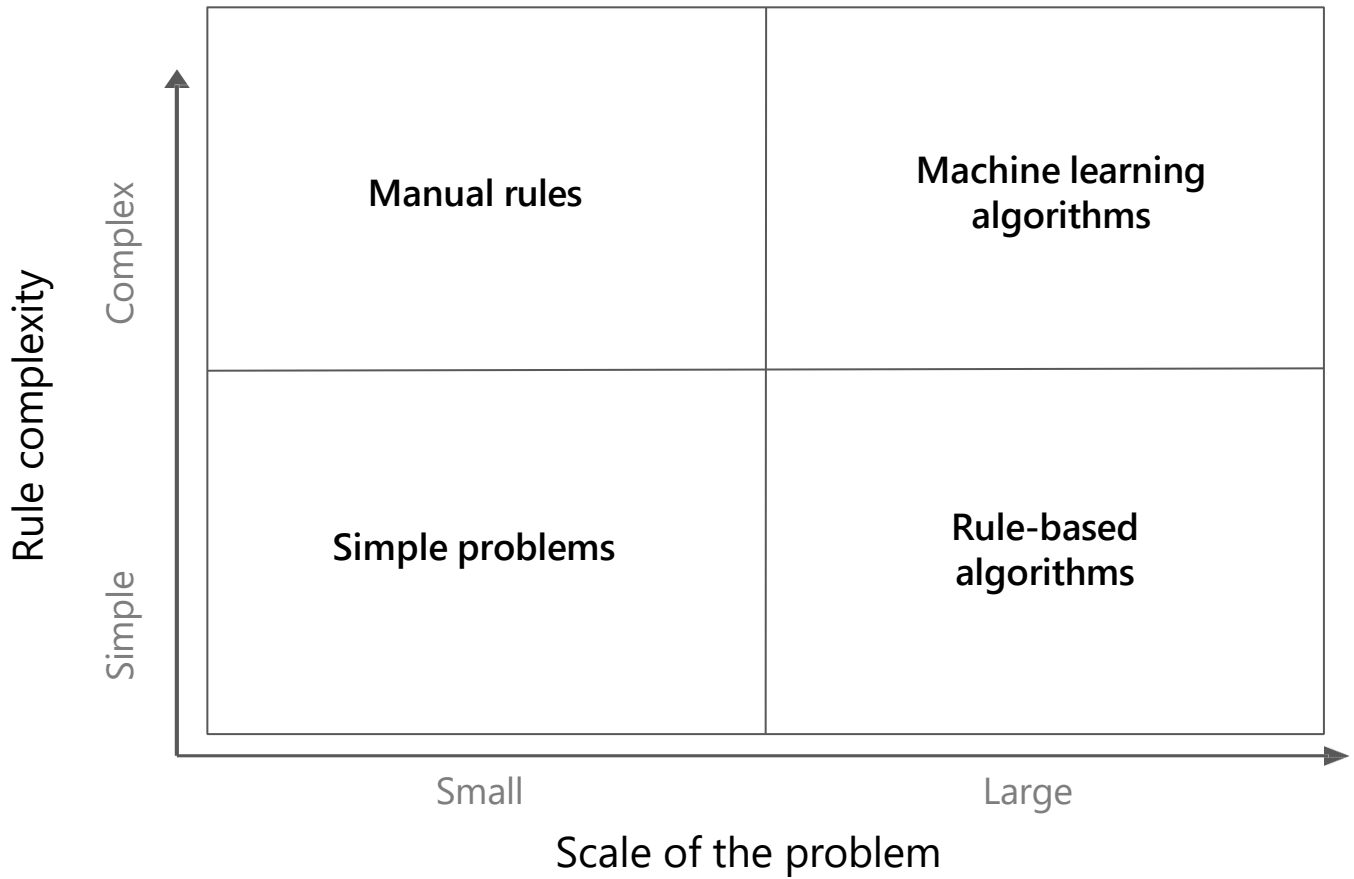

Machine Learning

Idéia

- **A função alvo f é desconhecida. Os algoritmos de aprendizado não conseguem obter uma função f perfeita.**
- **Assuma que a função hipótese g aproxima a função f, mas pode ser diferente da função f.**

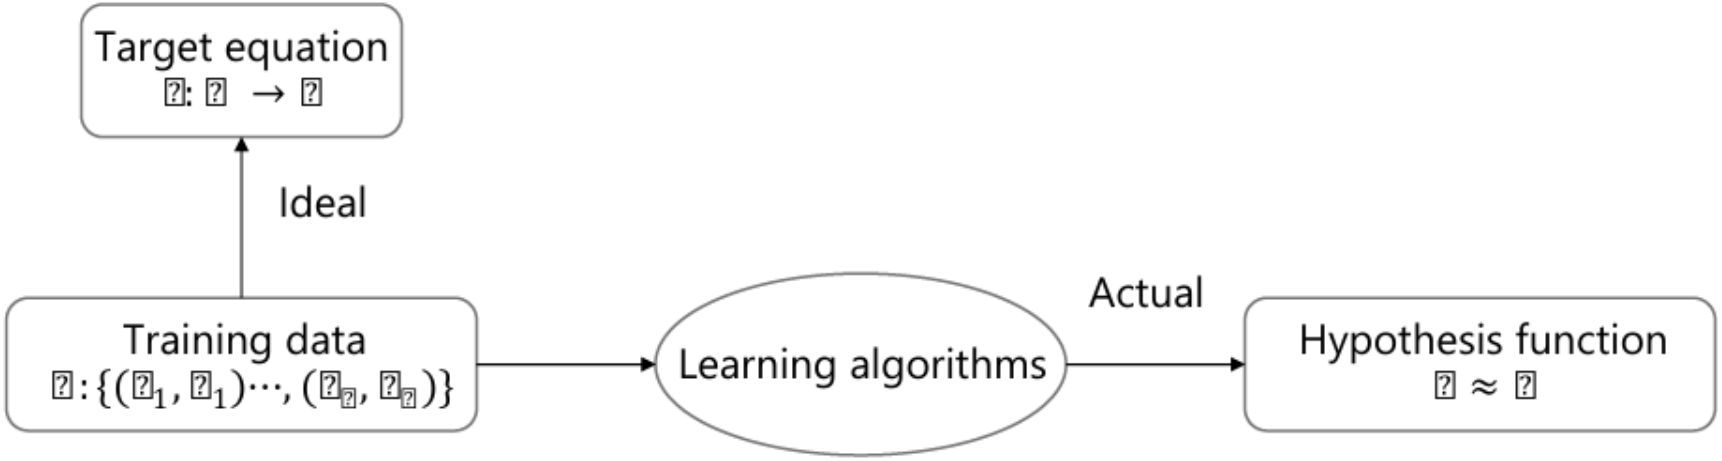

Machine Learning

Principais tipos de problemas

- **Classificação**
  - ✓ Um programa de computador precisa especificar a qual das k categorias um determinado input pertence.
  - ✓ Para realizar essa tarefa, os algoritmos de aprendizado geralmente geram uma função $f{:}X \rightarrow \{1,2,\ldots,k\}$. Por exemplo, o algoritmo de classificação de imagens em visão computacional é desenvolvido para lidar com tarefas de classificação.

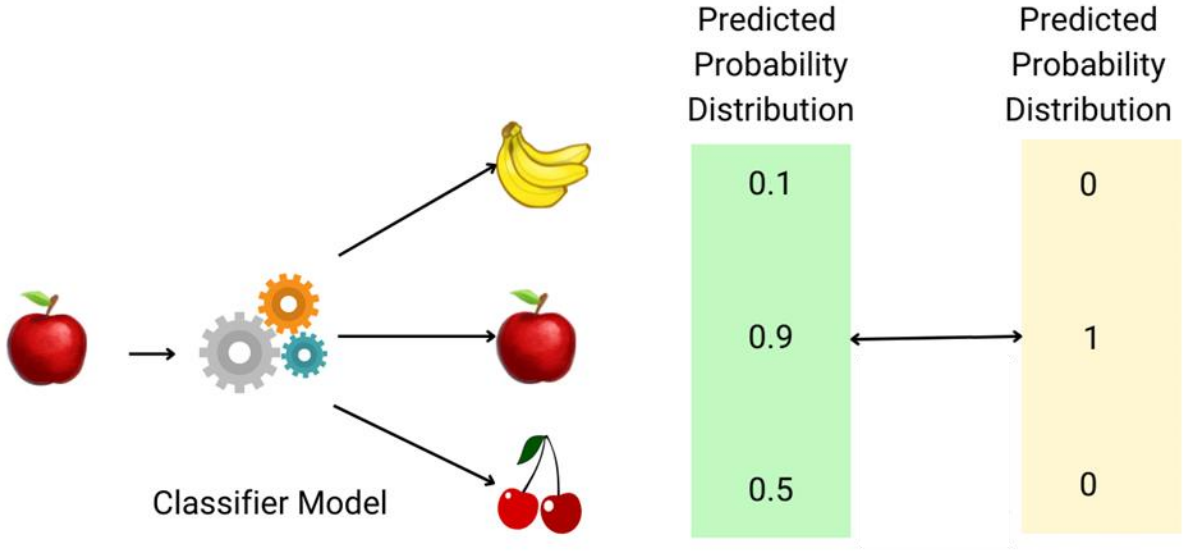

Machine Learning

Principais tipos de problemas

- **Regressão**
  - ✓ um programa de computador prevê a saída para um dado input. Os algoritmos de aprendizado normalmente geram uma função $f: X \rightarrow Y$, onde Y é um valor contínuo.
  - ✓ Um exemplo desse tipo de tarefa é prever o valor de uma ação.

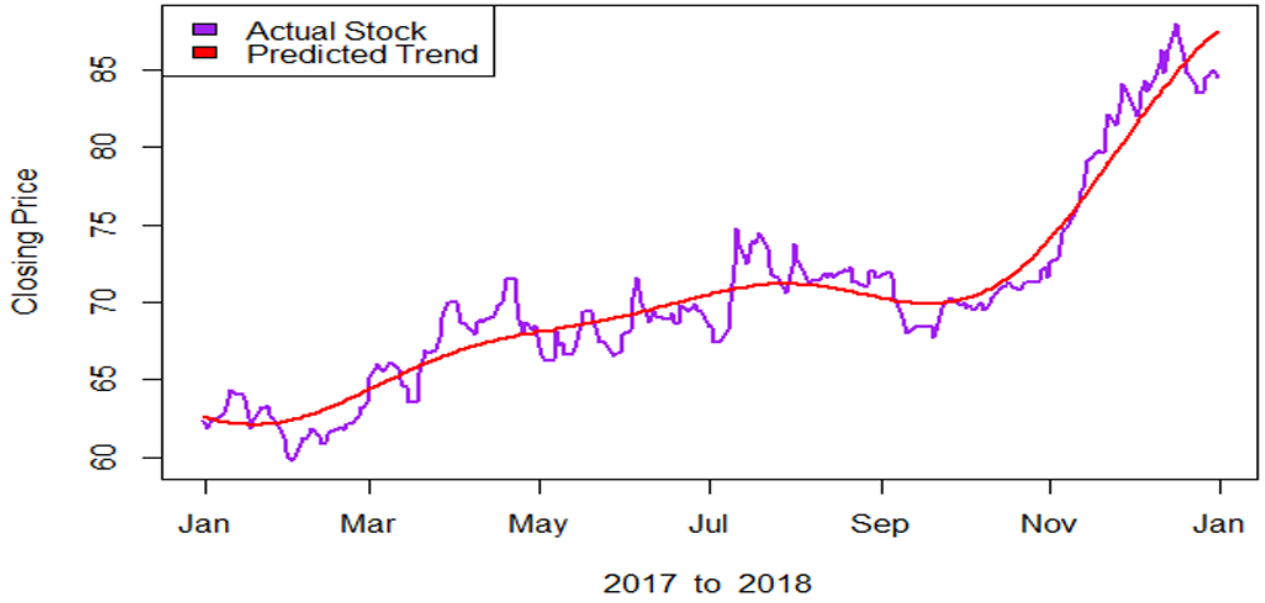

Machine Learning

Principais tipos de problemas

- **Clusterização**
  - ✓ Uma grande quantidade de dados de um conjunto de dados não rotulados é dividida em várias categorias com base na semelhança interna dos dados.
  - ✓ Dados na mesma categoria são mais semelhantes entre si do que os dados em categorias diferentes.

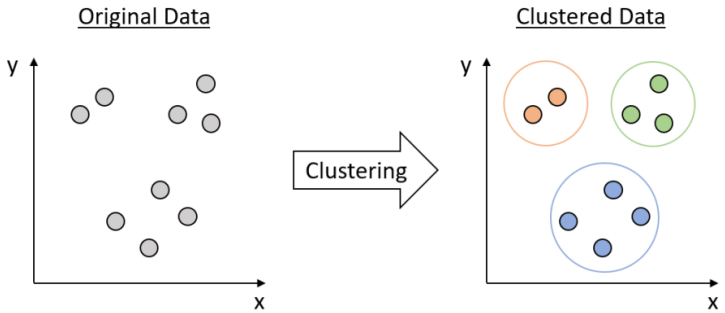

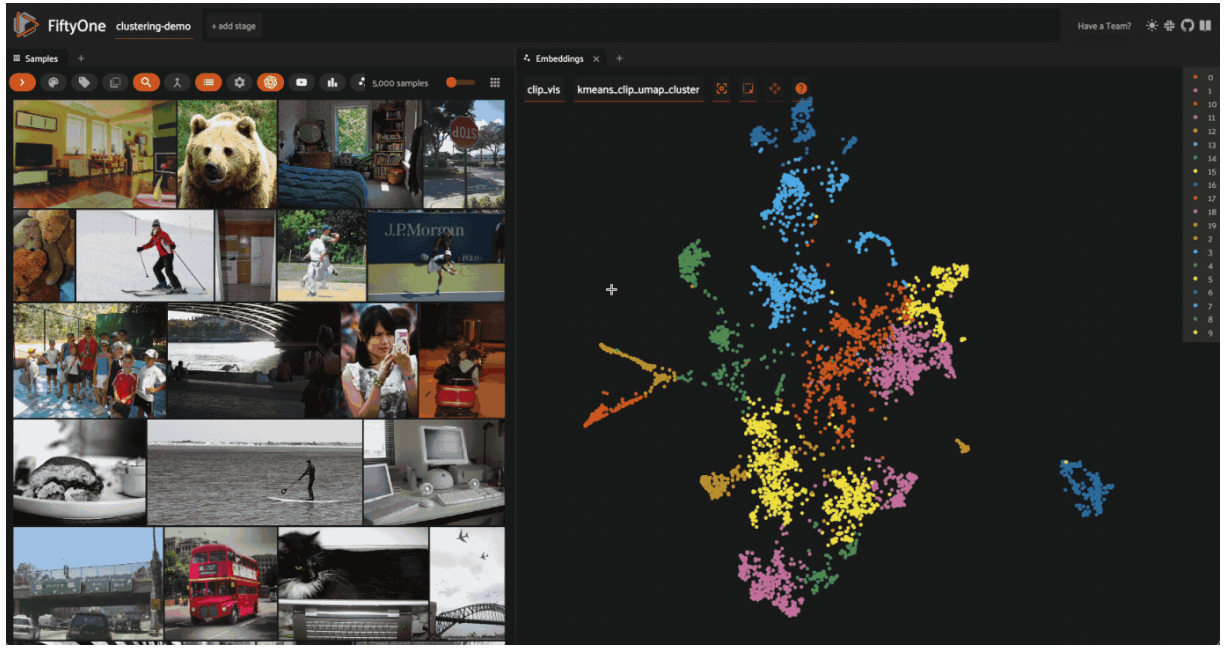

Machine Learning

Tipos de Aprendizado

- **Supervisionado**
  - ✓ Obter um modelo ótimo com o desempenho necessário através do treinamento e aprendizado com base nas amostras de categorias conhecidas.
  - ✓ Em seguida, usa-se o modelo para mapear todas as entradas para as saídas e verificar a saída com o objetivo de classificar dados desconhecidos.

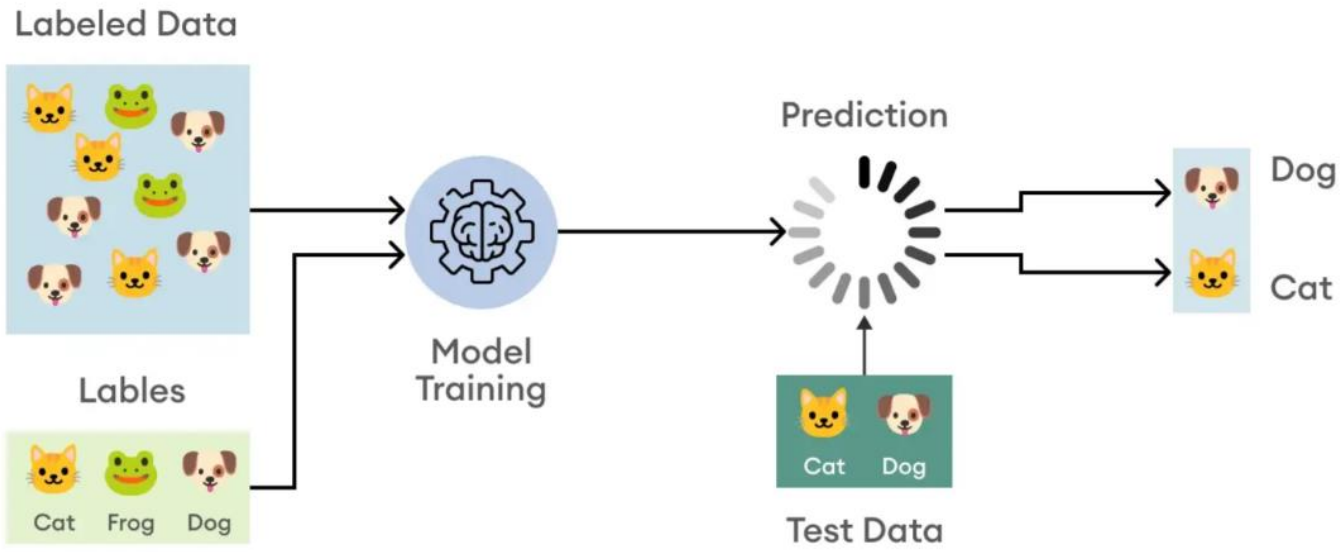

Machine Learning

Tipos de Aprendizado

- **Não-Supervisionado**
  - ✓ Para amostras não rotuladas, os algoritmos de aprendizado modelam diretamente os conjuntos de dados de entrada. O agrupamento (clustering) é uma forma comum de aprendizado não supervisionado.
  - ✓ Nesse caso, precisamos apenas agrupar amostras altamente semelhantes, calcular a similaridade entre novas amostras e as existentes, e classificá-las com base nessa similaridade.

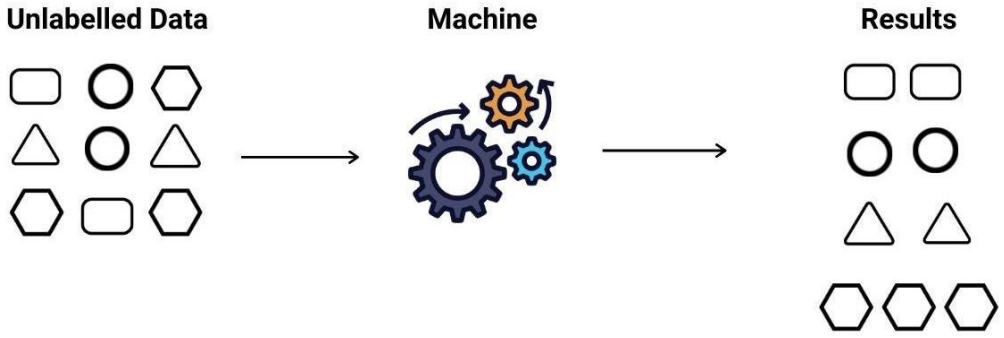

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço**
  - ✓ Se preocupa com a forma como os agentes devem tomar ações em um ambiente para maximizar uma noção de recompensa acumulada.
  - ✓ A diferença entre o aprendizado por reforço e o aprendizado supervisionado está no sinal do professor. O sinal de reforço fornecido pelo ambiente no aprendizado por reforço é usado para avaliar a ação em vez de dizer ao sistema de aprendizado como realizar as ações corretas.

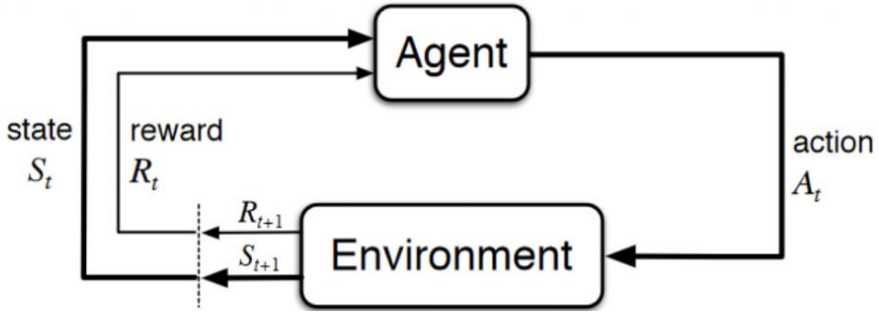

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Pavlov**
  - ✓ O experimento de Pavlov é um dos mais famosos estudos de condicionamento clássico na psicologia.
  - ✓ Ivan Pavlov, um fisiologista russo fez uma descoberta acidental que acabou sendo fundamental para o desenvolvimento da teoria do condicionamento clássico.
    - ✓ Pavlov estava realizando uma pesquisa sobre o sistema digestivo
    - ✓ Ele observou que, ao apresentar comida aos cães, eles começavam a salivar antes mesmo de ingerir o alimento
    - ✓ Esse reflexo antecipado da salivação não era esperado e despertou seu interesse
  - ✓ Investigação
    - ✓ Por que os cães salivavam em resposta a estímulos que estavam associados à comida, como a visão do alimento ou o som de um sino?

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Pavlov**
  - ✓ O experimento de Pavlov é um dos mais famosos estudos de condicionamento clássico na psicologia.
  - ✓ Ivan Pavlov, fez uma descoberta acidental que acabou sendo fundamental para o desenvolvimento da teoria do condicionamento clássico.
    - ✓ Pavlov estava realizando uma pesquisa sobre o sistema digestivo
    - ✓ Observou que, ao apresentar comida aos cães, eles começavam a salivar antes mesmo de ingerir o alimento
    - ✓ Esse reflexo antecipado da salivação não era esperado e despertou seu interesse

- Investigação
  - ✓ Por que os cães salivavam em resposta a estímulos que estavam associados à comida, como a visão do alimento ou o som de um sino?

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Pavlov**
  - ✓ Pavlov começou a realizar experimentos controlados com uso de um sino como estímulo neutro (um estímulo que, inicialmente, não causava resposta nos cães)
  - ✓ Fase de aquisição (condicionamento)
    - ✓ Pavlov tocava o sino antes de apresentar a comida aos cães.
    - ✓ Depois de várias repetições, os cães começaram a associar o som do sino com a chegada do alimento
  - ✓ Fase de teste
    - ✓ Após várias associações, Pavlov tocava o sino sem apresentar comida, e os cães começavam a salivar, mesmo sem a presença do alimento.
    - ✓ Isso demonstrou que eles haviam aprendido a associar o som do sino à comida.
  - ✓ Seu trabalho foi publicado em 1904, quando ele recebeu o Prêmio Nobel de Fisiologia ou Medicina

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Pavlov**

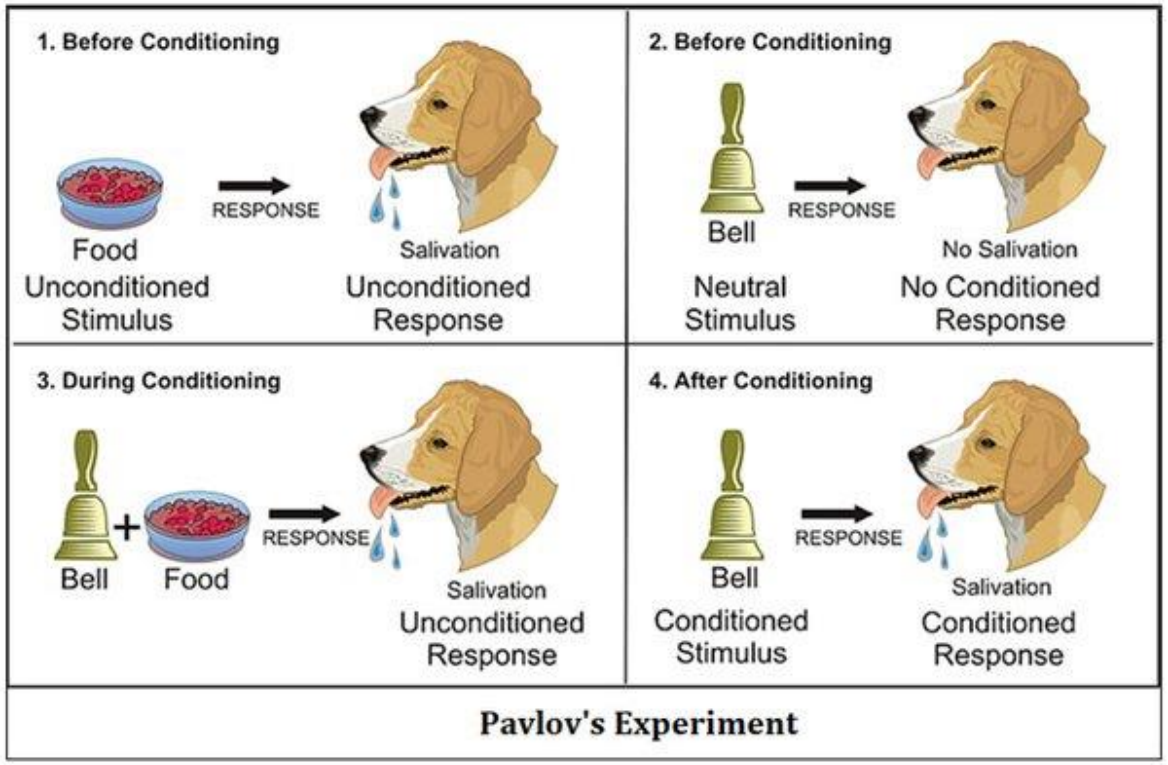

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Pavlov**
  - ✓ No aprendizado por reforço, um agente aprende a tomar decisões em um ambiente para maximizar a recompensa acumulada ao longo do tempo
    - ✓ **A idéia de associar ações a recompensas é fundamental**
    - ✓ **Pavlov, portanto, contribuiu para o entendimento de como os sistemas podem aprender e se adaptar com base no feedback do ambiente**
  - ✓ Assim como Pavlov mostrou que um estímulo condicionado (o sino) pode provocar uma resposta automática (salivação), no aprendizado por reforço, as ações do agente podem se tornar condicionadas a certos estados do ambiente, dependendo das recompensas que o agente recebe ao longo do tempo.
  - ✓ Mais tarde seria formalizado em modelos de aprendizado por reforço, como os de Q-learning ou os algoritmos de política, que associam ações a recompensas específicas para maximizar a performance do agente ao longo do tempo

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Skinner**
  - ✓ Enquanto Pavlov focou no condicionamento clássico, que se baseia em associar um estímulo a uma resposta, Skinner se concentrou no condicionamento operante
    - ✓ **Se refere ao processo pelo qual as consequências de uma ação influenciam a probabilidade dessa ação ser repetida**
    - ✓ **A ação do organismo é vista de maneira ativa sobre o ambiente e é recompensado ou punido com base nas suas ações**
  - ✓ Skinner acreditava que o comportamento humano e animal é controlado por suas consequências e que comportamentos podem ser reforçados ou desencorajados com base nos resultados que seguem as ações.
    - ✓ **Reforços e punições são usados para aumentar ou diminuir a probabilidade de um comportamento ocorrer novamente**

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Skinner**
  - ✓ A caixa de Skinner consistia em uma câmara fechada onde um animal podia realizar uma ação (por exemplo, pressionar uma alavanca) para obter uma recompensa, geralmente comida
  - ✓ A caixa permitia que ele manipulasse variáveis como o tipo de reforço (positivo ou negativo), o intervalo de tempo entre a ação e a recompensa, e a frequência de reforços. Skinner identificou três tipos de consequências para o comportamento
  - ✓ Skinner acreditava que o comportamento humano e animal é controlado por suas consequências e que comportamentos podem ser reforçados ou desencorajados com base nos resultados que seguem as ações.
    - ✓ **Reforços e punições são usados para aumentar ou diminuir a probabilidade de um comportamento ocorrer novamente**

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Skinner**
  - ✓ A caixa permitia que ele manipulasse variáveis como o tipo de reforço (positivo ou negativo), o intervalo de tempo entre a ação e a recompensa, e a frequência de reforços. Skinner identificou três tipos de consequências para o comportamento

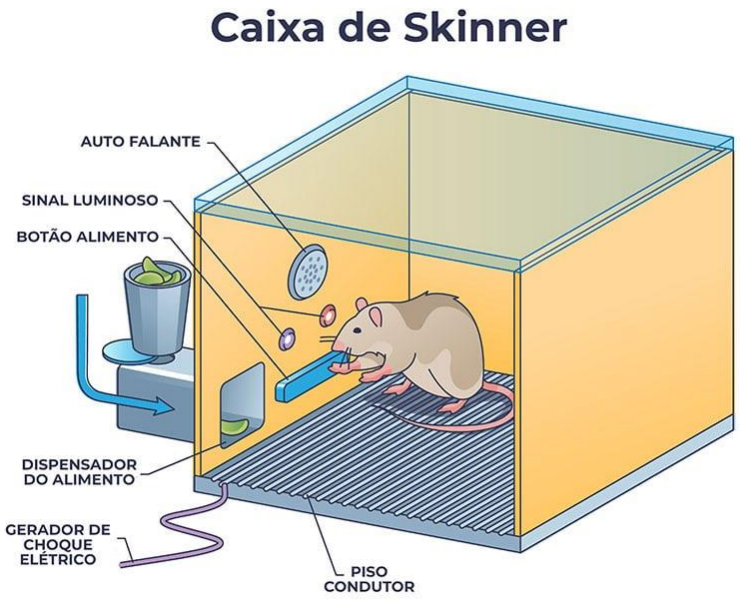

Machine Learning

Tipos de Aprendizado

- **Aprendizado por reforço – curiosidade – Experimento de Skinner**

  - ✓ **Reflexos positivos**: Quando um comportamento é seguido por uma recompensa (reforço positivo), a probabilidade de o comportamento ser repetido aumenta.
  - ✓ **Reflexos negativos**: Quando um comportamento é seguido pela remoção de um estímulo aversivo (reforço negativo), também aumenta a probabilidade de o comportamento ser repetido.
  - ✓ **Punições**: Quando um comportamento é seguido por uma consequência desagradável, a probabilidade de esse comportamento ocorrer novamente diminui.

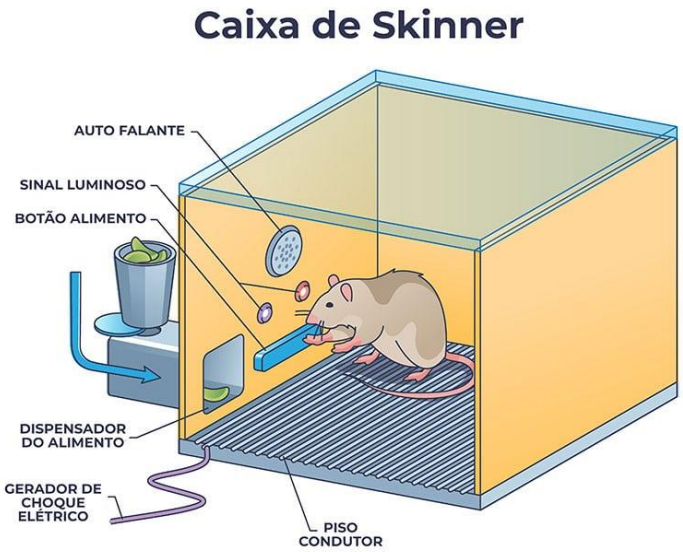

Machine Learning

Aprendizado Supervisionado

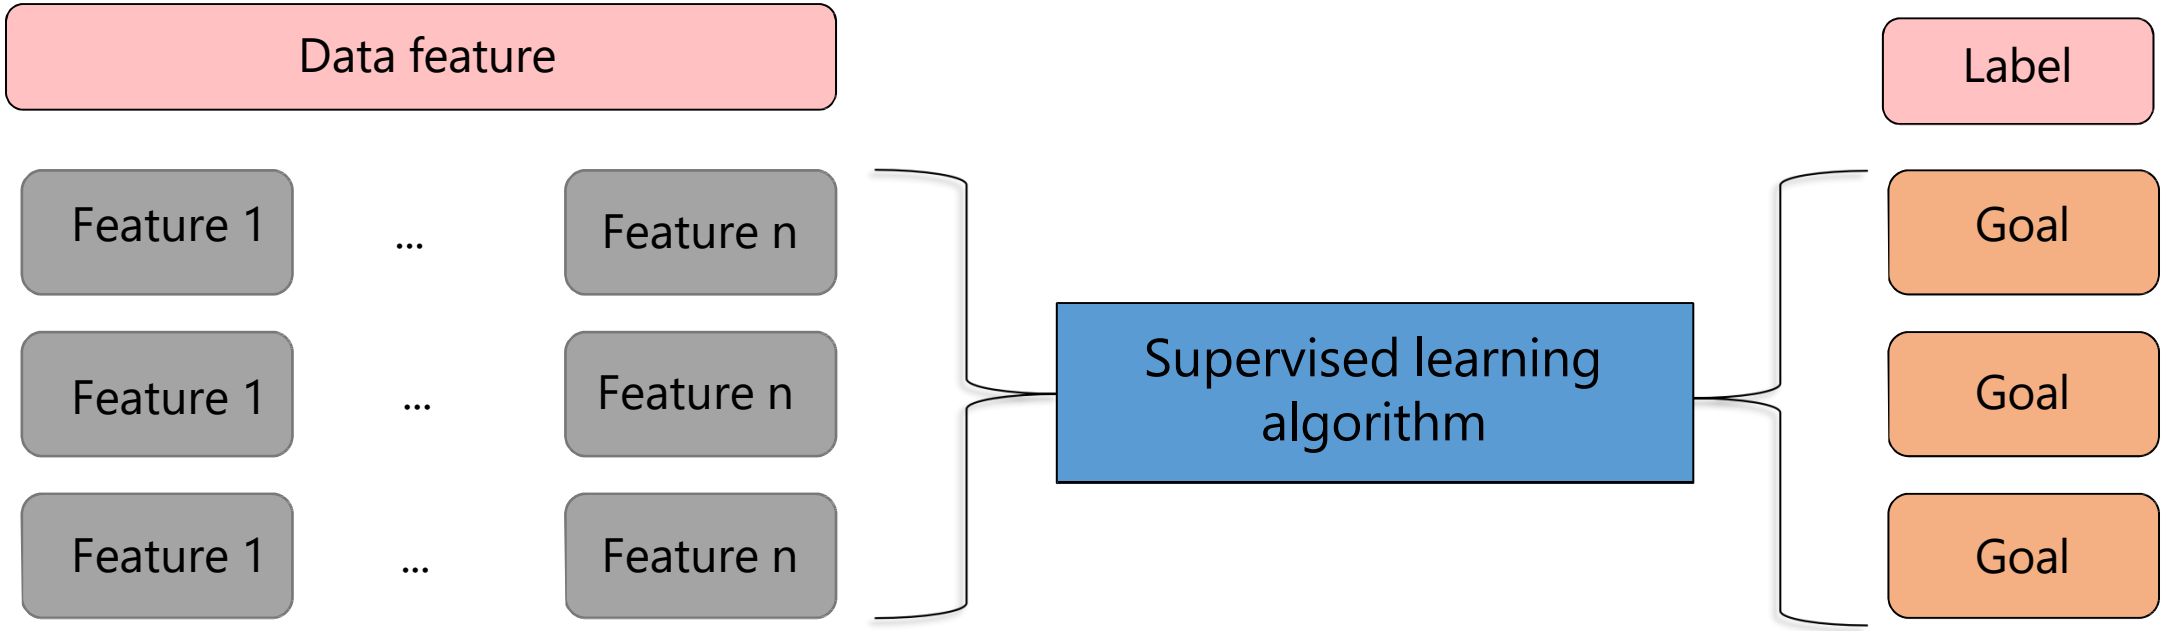

Weather	Temperature	Wind Speed
Sunny	Warm	Strong
Rainy	Cold	Fair
Sunny	Cold	Weak

Enjoy Sports
Yes
No
Yes

Machine Learning

Classificação

- **Mapeia amostras em um conjunto de dados amostral para uma categoria específica usando um modelo de classificação.**

- **Responde a perguntas como:**
  - ✓ Haverá um engarrafamento na estrada XX durante o ã amanhã?
  - ✓ Qual método é mais atraente para os clientes: um vou e desconto?

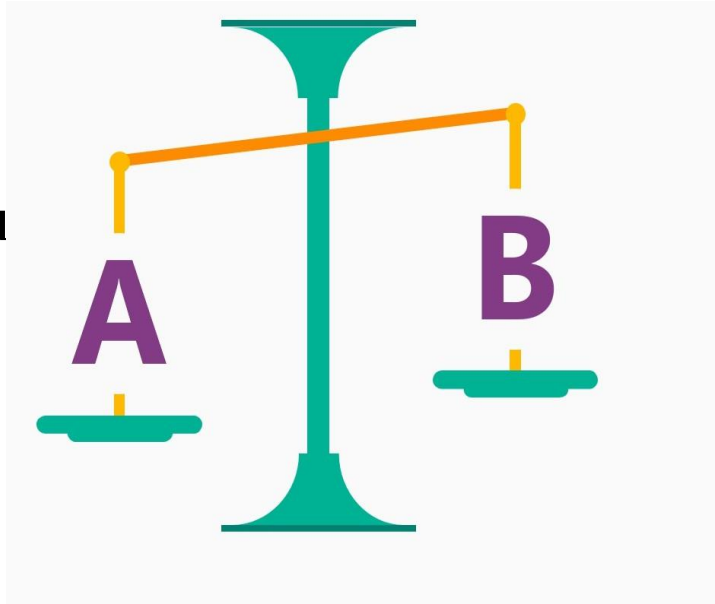

Machine Learning

Conceitos básicos - pipeline geral

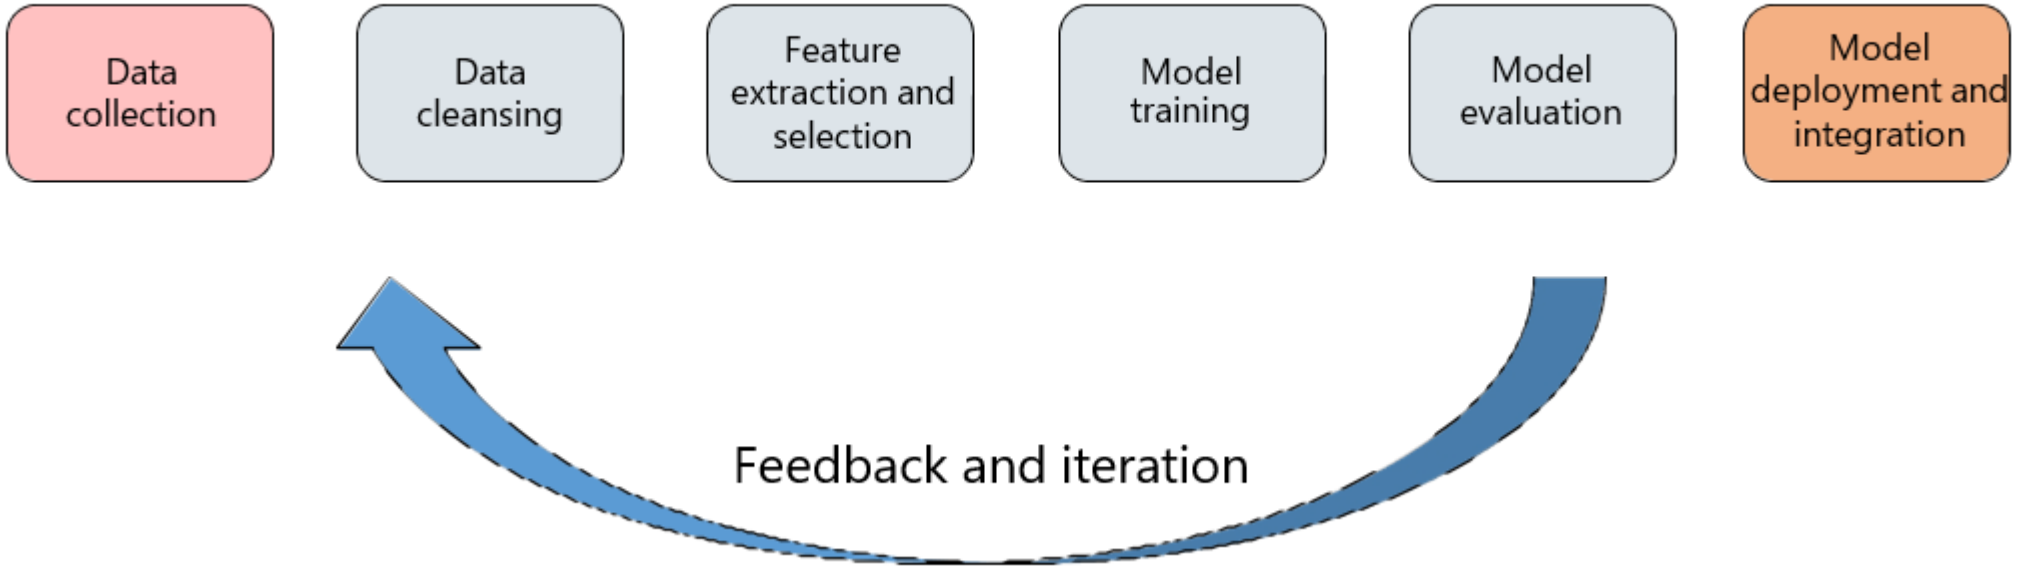

Machine Learning

Conceitos básicos – pipeline de construção do modelo

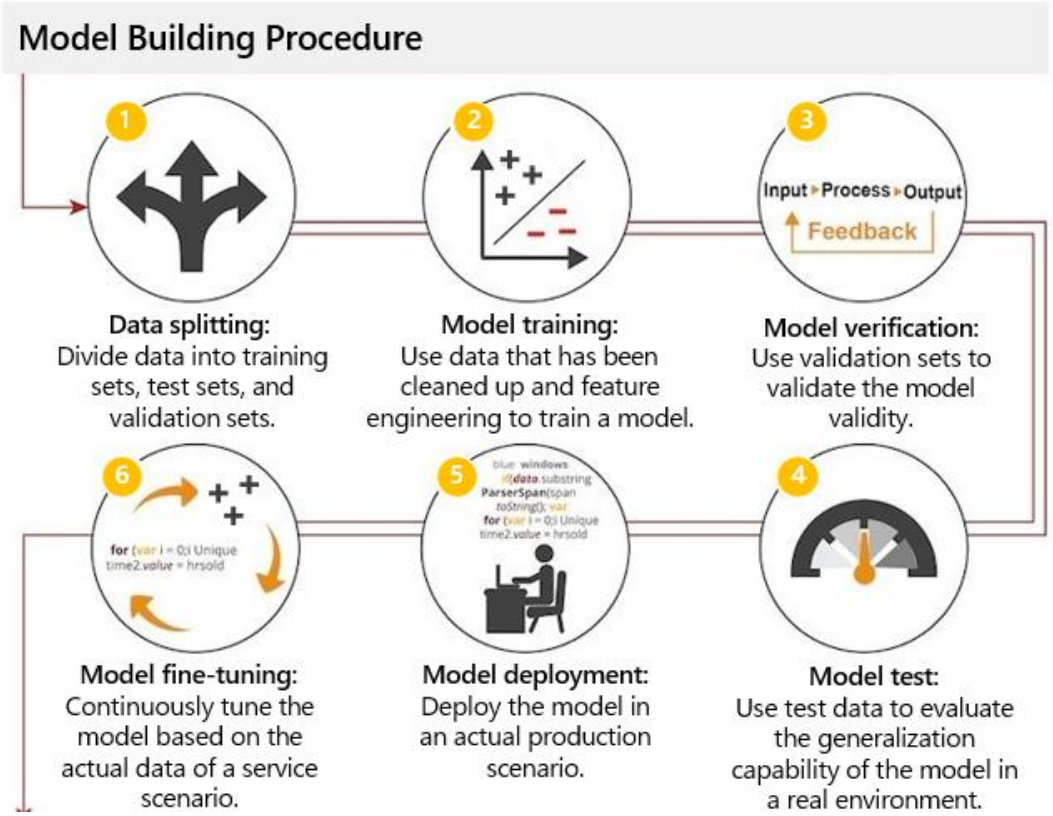

Machine Learning

Conceitos básicos - dataset

- **Conjunto de dados (Dataset)**
  - ✓ Uma coleção de dados usada em tarefas de aprendizado de máquina.
  - ✓ Cada registro de dados é chamado de amostra.
  - ✓ Os eventos ou atributos que refletem o desempenho ou a natureza de uma amostra em um determinado aspecto são chamados de características (features).
  - ✓ Labels refletem a resposta esperada para cada amostra.

		Feature 1	Feature 2	Feature 3	Label
	No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000
	2	120	9	Southwest	1300
	3	60	6	North	700
	4	80	9	Southeast	1100
Test set	5	95	3	South	850

Machine Learning

Conceitos básicos – divisão de dados

- **Hold-out**
  - ✓ É o método mais simples de validação. Consiste em separar os dados em duas (ou três) partes: Treino, Teste e possível terceira subdivisão (Validação) [opcional]
  - ✓ Como é feito? Escolhe-se uma proporção de partição (ex: 80-20 ou 60-20-20)
  - ✓ Vantagens
    - ✓ Simplicidade: fácil de implementar; basta dividir os dados uma única vez.
    - ✓ Rapidez: ideal quando o conjunto de dados é grande e o treinamento precisa ser mais ágil.
  - ✓ Desvantagens
    - ✓ Dependência da partição: se os dados forem divididos de forma desfavorável (por exemplo, desbalanceados em alguma parte), a avaliação pode não refletir bem o desempenho real.
    - ✓ Menor aproveitamento dos dados para treino: se você separa 30% ou mais para teste, está “perdendo” dados que poderiam ajudar no treinamento.

Machine Learning

Divisão de dados – hold-out

		Feature 1	Feature 2	Feature 3	Label
	No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000
	2	120	9	Southwest	1300
	3	60	6	North	700
	4	80	9	Southeast	1100
Test set	5	95	3	South	850

Machine Learning

Divisão de dados – hold-out

- **Conjunto de treinamento (Training set)**
  - ✓ Um conjunto de dados usado no processo de treinamento, onde cada amostra é chamada de amostra de treinamento.
  - ✓ O processo de criação de um modelo a partir dos dados é chamado de aprendizado (treinamento).
  - ✓ Geralmente é subdividido em 2 grupos: treino e validação, onde o primeiro é usado para ajustar o modelo e o segundo para simular **desempenho em dados novos**.

		Feature 1	Feature 2	Feature 3	Label
	No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000
	2	120	9	Southwest	1300
	3	60	6	North	700
	4	80	9	Southeast	1100
Test set	5	95	3	South	850

Ou tomar decisões sobre ajustes de parâmetros

Machine Learning

Divisão de dados – hold-out

- **Conjunto de teste (Test set)**
  - ✓ O teste refere-se ao processo de usar o modelo obtido após o treinamento para fazer previsões.
  - ✓ O conjunto de dados usado para esse propósito é chamado de conjunto de teste, e cada amostra é chamada de amostra de teste.
  - ✓ O teste nunca é utilizado para ajuste de modelos ou parâmetros. É usado para simular a aplicação do modelo em dados que você ainda não tem.

		Feature 1	Feature 2	Feature 3	Label
	No.	Area	School Districts	Direction	House Price
Training set	1	100	8	South	1000
	2	120	9	Southwest	1300
	3	60	6	North	700
	4	80	9	Southeast	1100
Test set	5	95	3	South	850

Machine Learning

Divisão de dados – Cross-Validation

- **Conceitos**
  - ✓ Faz várias partições e garantindo que, em alguma iteração, cada dado seja usado tanto para treino quanto para teste.

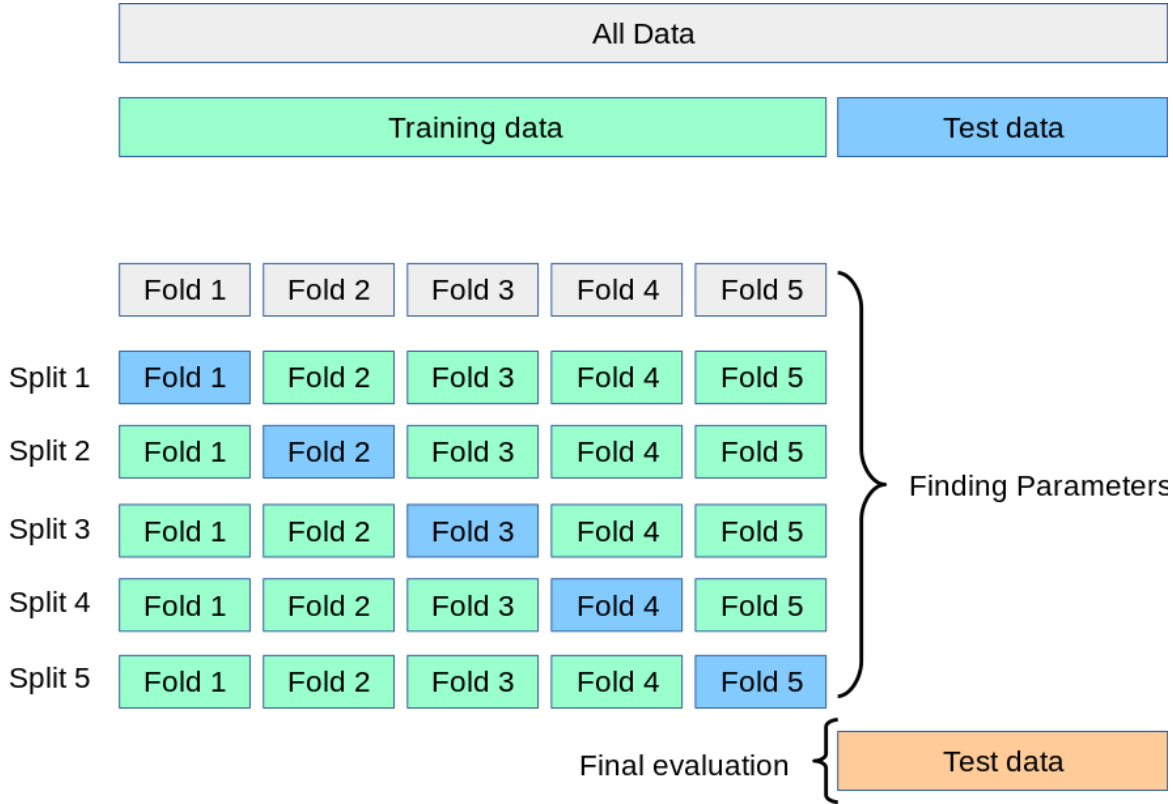

Machine Learning

Divisão de dados – Cross-Validation

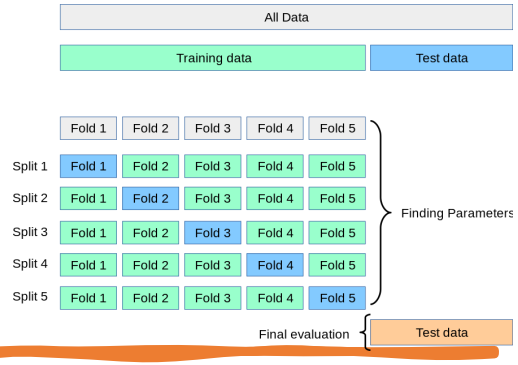

- **Conceitos**
  - ✓ Vantagens da Cross-Validation
    - ✓ Melhor uso dos dados: cada observação figura no conjunto de teste exatamente uma vez e no conjunto de treino k-1 vezes.
    - ✓ Estimativa mais estável do desempenho: reduz a dependência de uma única divisão train/test.
    - ✓ Robustez estatística: ao relatar a média e o desvio padrão do desempenho, temos uma ideia mais confiável da variância do estimador.
  - ✓ Desvantagens da Cross-Validation
    - ✓ Maior custo computacional: é necessário treinar o modelo k vezes, o que pode ser pesado se o modelo for complexo ou se o dataset for muito grande.
    - ✓ Complexidade de implementação: um pouco mais difícil do que um simples hold-out.

Machine Learning

Divisão de dados – Cross-Validation

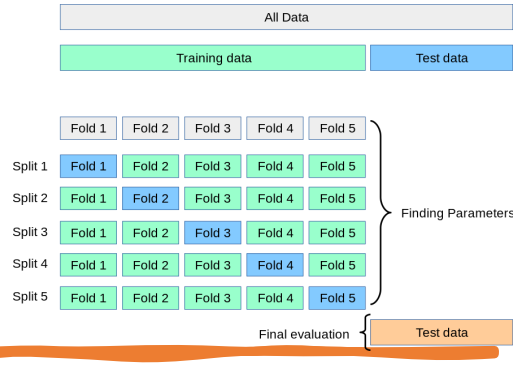

- **Como funciona (K-Fold Cross-Validation)**
  - ✓ Defina um valor k (por exemplo, k=5 ou k=10).
  - ✓ Divida o dataset em k partes (folds) de tamanhos aproximadamente iguais.
  - ✓ Para cada uma das k iterações:
    - ✓ Reserve 1 fold como conjunto de teste. Use as k-1 partes restantes como conjunto de treinamento.
    - ✓ Treine e avalie o modelo.
    - ✓ Calcule uma medida de desempenho (por exemplo, acurácia ou MSE) para cada iteração.
  - ✓ A métrica final será a média (e desvio padrão, opcionalmente) dos desempenhos obtidos nas k iterações.

Machine Learning

Divisão de dados – Cross-Validation

- **Exemplo**
  - ✓ Dividimos o dataset em 5 pastas (folds): F1, F2, F3, F4, F5.
  - ✓ Iteração 1: Treino = (F2, F3, F4, F5) | Teste = (F1)
  - ✓ Iteração 2: Treino = (F1, F3, F4, F5) | Teste = (F2)
  - ✓ Iteração 3: Treino = (F1, F2, F4, F5) | Teste = (F3)
  - ✓ Iteração 4: Treino = (F1, F2, F3, F5) | Teste = (F4)
  - ✓ Iteração 5: Treino = (F1, F2, F3, F4) | Teste = (F5)
  - ✓ Métrica final: média dos valores de cada iteração.

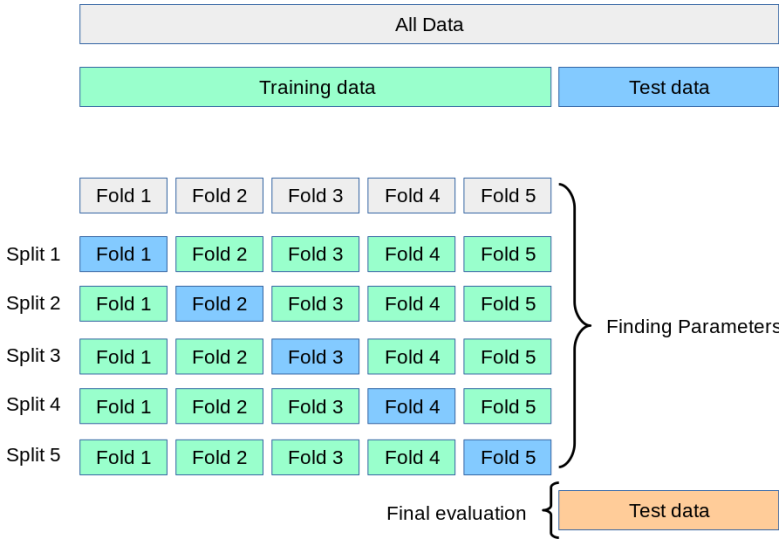

Machine Learning

Conceitos básicos – O que é um bom modelo?

- **Capacidade de Generalização**
  - ✓ Pode prever com precisão os dados reais do serviço?
- **Interpretabilidade**
  - ✓ O resultado da previsão é fácil de interpretar?
- **Velocidade de Previsão**
  - ✓ Quanto tempo leva para prever cada dado?
- **Praticidade**
  - ✓ A taxa de previsão ainda é aceitável quando o volume de serviço aumenta significativamente?

Machine Learning

Conceitos básicos – Validade do Modelo

- **Erro: Diferença entre o resultado previsto pelo modelo após o aprendizado e o resultado real da amostra**
  - ✓ Erro de treinamento: erro obtido ao executar o modelo nos dados de treinamento.
  - ✓ Erro de generalização: erro obtido ao executar o modelo em novas amostras. Obviamente, preferimos um modelo com um erro de generalização menor.
- **Underfitting (Subajuste)**
  - ✓ Ocorre quando o modelo ou o algoritmo não se ajusta bem o suficiente aos dados.
- **Overfitting (Sobreajuste)**
  - ✓ Ocorre quando o erro de treinamento do modelo, após o aprendizado, é pequeno, mas o erro de generalização é grande (indicando baixa capacidade de generalização)

Machine Learning

Conceitos básicos – Validade do Modelo

- **Capacidade do modelo: capacidade do modelo de ajustar funções, também chamada de complexidade do modelo.**
  - ✓ Modelos com capacidade insuficiente não conseguem resolver tarefas complexas, podendo ocorrer subajuste (underfitting).
  - ✓ Um modelo de alta capacidade pode resolver tarefas complexas, mas o sobreajuste (overfitting) pode ocorrer se a capacidade for maior do que a necessária para a tarefa.

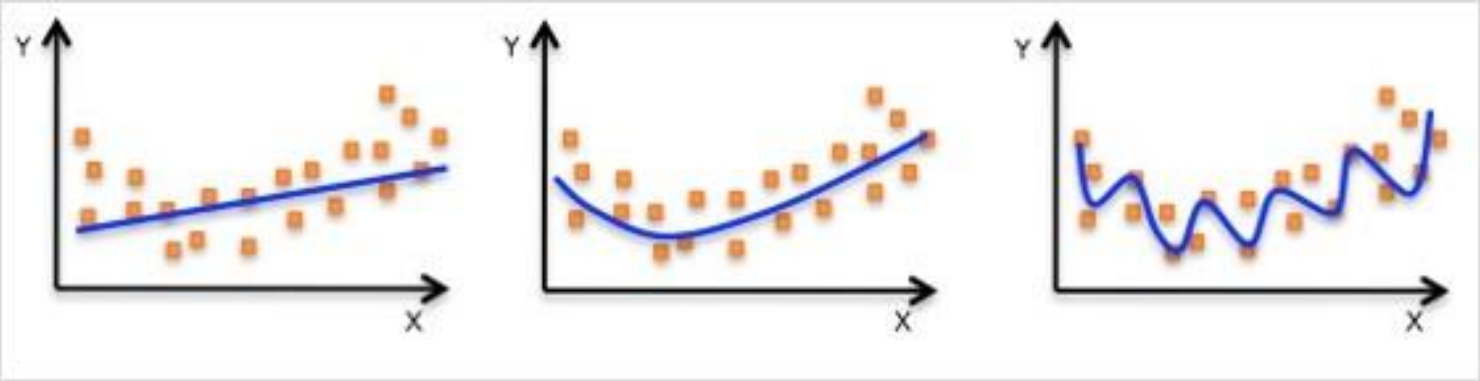

Underfitting
Not all features are learned.

Good fitting

Overfitting
Noises are learned.

Machine Learning

Conceitos básicos – Validade do Modelo

- **Geralmente, o erro de previsão pode ser dividido em dois tipos: Erro de Variância e Erro de Viés**
  - ✓ Baixo viés & baixa variância → Bom modelo
  - ✓ Baixo viés & alta variância
  - ✓ Alto viés & baixa variância
  - ✓ Alto viés & alta variância → Modelo ruim
  - ✓ Idealmente, queremos um modelo que possa capturar com precisão as regras nos dados de treinamento e resumir os dados invisíveis (novos dados). No entanto, geralmente é impossível para o modelo realizar ambas as tarefas ao mesmo tempo

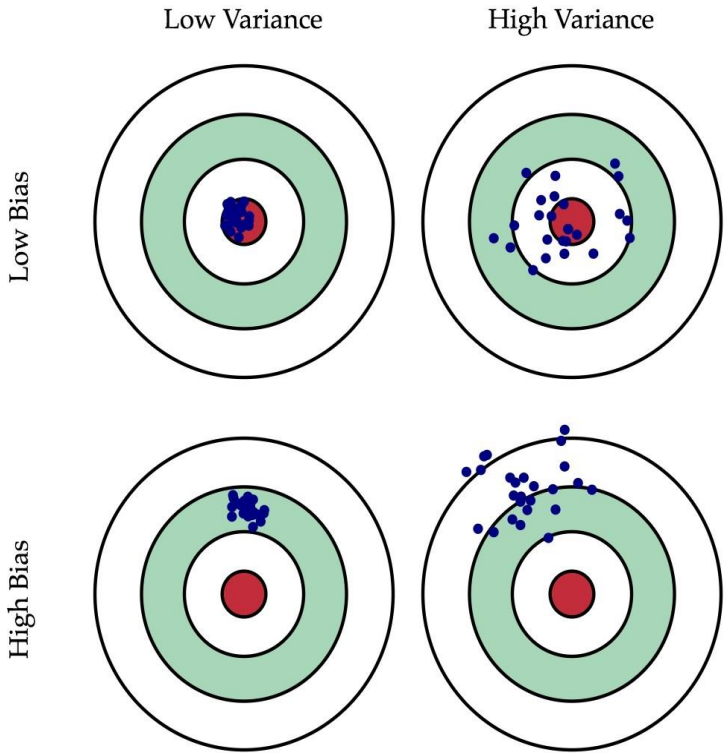

Machine Learning

Conceitos básicos – Validade do Modelo

- **Complexidade do Modelo e Erro**
  - ✓ À medida que a complexidade do modelo aumenta, o erro de treinamento diminui.
  - ✓ À medida que a complexidade do modelo aumenta, o erro de teste diminui até certo ponto e depois começa a aumentar novamente, formando uma curva convexa.

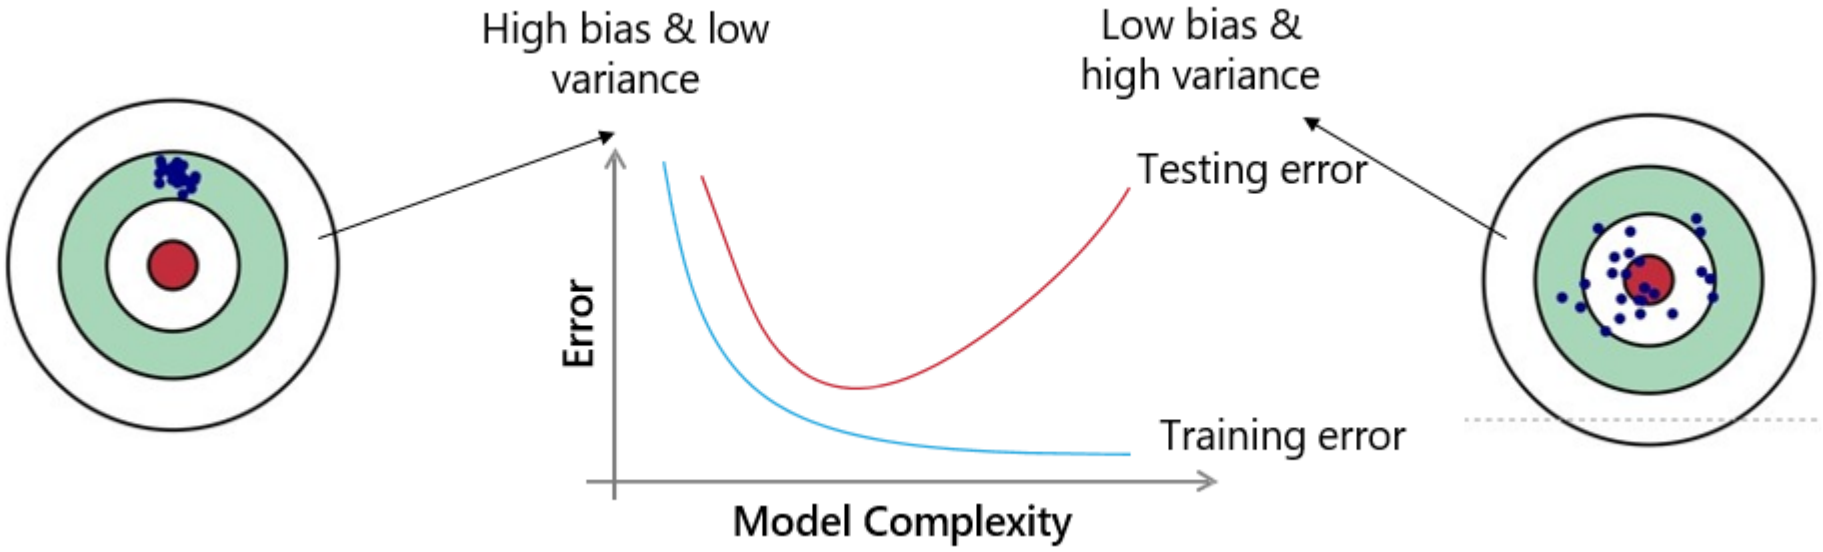

Machine Learning

Avaliação do modelo - Classificação

- **MAE (Mean Absolute Percentage Error)**
  - ✓ É a média dos valores absolutos das diferenças entre o valor real e o valor predito.
  - ✓ Quanto mais próximo de 0, melhor o modelo se ajusta aos dados de treinamento.
  - ✓ Indica, em média, o tamanho do erro (sem sinal) entre predição e valor real.
    - ✓ É fácil de interpretar, pois está na mesma escala da variável-alvo (por exemplo, se você estiver prevendo preços em Reais, a MAE estará em Reais).
    - ✓ **Exemplo:** Se você tem um modelo que prediz o preço de imóveis em uma cidade e descobre que o MAE é de R$ 5.000, isso significa que, em média, o modelo erra cerca de R$ 5.000 em cada previsão de preço.
    - ✓ Mais robusto a outliers em comparação ao MSE, pois não eleva ao quadrado as diferenças.

$$MAE = \frac{1}{m}\sum_{i=1}^{m} |y_i - \hat{y}_i|$$

Machine Learning

Avaliação do modelo - Classificação

- **Erro Médio Quadrático (MSE)**
  - ✓ É a média dos quadrados das diferenças entre o valor real e o valor predito.
  - ✓ O MSE penaliza mais fortemente erros grandes (outliers) em comparação ao MAE.
    - ✓ Muito utilizado como função de custo em regressão linear e outros modelos de Machine Learning (por exemplo, Redes Neurais)
    - ✓ Se existirem valores atípicos extremamente altos ou baixos, o MSE aumentará consideravelmente, chamando atenção para esses grandes erros
  - ✓ Se o MSE é de 2,5×10^8, significa que em média (ao quadrado) o erro é de 15.811 (raiz de 2,5×10^8). Essa interpretação não está diretamente na escala do preço (por isso muitas vezes preferimos também analisar o RMSE, como veremos adiante).

$$MSE = \frac{1}{m}\sum_{i=1}^{m}(y_i - \hat{y}_i)^2$$

Machine Learning

Avaliação do modelo - Classificação

- **MAPE (Mean Absolute Percentage Error)**
  - ✓ Calcula a média dos erros em termos percentuais, ou seja, leva em conta o quão grande é o erro em relação ao valor real.
    - ✓ Indica, em média, qual a porcentagem de desvio em relação ao valor real
    - ✓ Cuidado: se yi for muito próximo de zero, o MAPE pode explodir ou ficar impreciso.
  - ✓ **Quando usar**: cenários em que o tamanho relativo do erro interessa mais do que o erro absoluto (em vendas é importante saber se erramos 10% ou 50% das vendas)
    - ✓ Na previsão de vendas de uma loja, podemos dizer que o modelo erra em média 8% das vendas diárias. Independentemente de a loja vender 100 ou 1000 itens por dia, essa taxa de erro percentual mantém a comparação coerente.

$$MAPE = \frac{1}{m}\sum_{i=1}^{m} \left| \frac{y_i - \hat{y}_i}{y_i} \right|$$

Machine Learning

Avaliação do modelo - Classificação

- **RMSE (Root Mean Squared Error)**
  - ✓ É simplesmente a raiz quadrada do MSE
  - ✓ Interpretação na mesma unidade dos valores de saída, porém preservando a ideia de penalizar mais erros grandes.
    - ✓ É frequentemente utilizado para ter uma noção de erro na mesma escala do problema.
    - ✓ Útil em tarefas onde erros maiores devam pesar mais, mas ainda se deseje uma métrica "na unidade" do que se está prevendo.
  - ✓ Exemplo: Na previsão de temperatura (em graus Celsius), o RMSE de 2°C indica, aproximadamente, que no "quadrado médio" das previsões, o desvio gira em torno de 2 graus em relação ao valor real.

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(y_i - \hat{y}_i)^2}$$

Machine Learning

Avaliação do modelo - Classificação

- **Conclusão e Escolha da Métrica**
  - ✓ Não existe “melhor” métrica absoluta: a escolha depende do contexto.
  - ✓ Se você quer simplicidade e não deseja penalizar erros grandes excessivamente, MAE ou MAPE (se preferir porcentagens) podem ser mais apropriados.
  - ✓ Se você quer focar na minimização de grandes erros ou usar métodos tradicionais de otimização de regressão, opte por MSE ou RMSE.
  - ✓ Se comparações relativas são importantes (por exemplo, comparar erros em diferentes escalas ou em diferentes produtos/projetos), MAPE pode ser o mais intuitivo.

Machine Learning

Avaliação do modelo - Classificação

Real \ Predito	SIM	NAO	Total
SIM	TP	FN	
NAO	FP	TN	
Total	P	N	P+N

- **Termos e definições**
  - ✓ P: Positivo, indicando o número de casos realmente positivos nos dados.
  - ✓ N: Negativo, indicando o número de casos realmente negativos nos dados.
  - ✓ TP (True Positive ou Verdadeiro Positivo): número de casos positivos que são classificados corretamente pelo classificador.
  - ✓ TN (True Negative ou Verdadeiro Negativo): número de casos negativos que são classificados corretamente pelo classificador.
  - ✓ FP (False Positive ou Falso Positivo): número de casos positivos classificados incorretamente (ou seja, deveriam ser “sim”, mas classificou-se como “não”).
  - ✓ FN (False Negative ou Falso Negativo): número de casos negativos que são classificados incorretamente (ou seja, deveriam ser “não”, mas classificou-se como “sim”).

Machine Learning

Avaliação do modelo - Classificação

- **Matriz de confusão**
  - ✓ Uma tabela de dimensão 2×2. O valor cij das primeiras 2 linhas e 2 colunas indica quantos casos que de fato pertencem à classe i foram classificados como classe j pelo classificador.
  - ✓ Idealmente, para um classificador com alta exatidão, a maior parte das predições deve estar concentrada na diagonal que vai de $c1,1$ a $c2,2$. Ou seja, desejamos que FP e FN sejam próximos de 0.

Predito / Real	SIM	NAO	Total
SIM	TP	FN	
NAO	FP	TN	
Total	P	N	P+N

Machine Learning

Avaliação do modelo - Classificação

Real \ Predito	SIM	NAO	Total
SIM	TP	FN	
NAO	FP	TN	
Total	P	N	P+N

Medida	Fórmula
Acurácia ou **Taxa de Reconhecimento**	$\frac{TP+TN}{P+N}$
Taxa de Erro ou **Taxa de Misclassificação**	$\frac{FP+FN}{P+N}$
Sensibilidade, Taxa de Verdadeiros Positivos ou **Recall**	$\frac{TP}{P}$
Especificidade ou **Taxa de Verdadeiros Negativos**	$\frac{TN}{N}$
Precisão	$\frac{TP}{TP+FP}$
F1, média harmônica de **Recall** e **Precisão**	$2\ x\ \frac{Precisão\ x\ Recall}{Precisão + Recall}$
Fβ, onde β é um número real não negativo	$(1+\beta^2)\ x\ \frac{Precisão\ x\ Recall}{\beta^2\ x\ Precisão + Recall}$

Machine Learning

Avaliação do modelo - Classificação

- **Exemplo**
  - ✓ Treinamos um modelo de machine learning para identificar se o objeto em uma imagem é um gato. Utilizamos 200 imagens para verificar o desempenho do modelo. Das 200 imagens, em 170 há gatos (positivo real) e em 30 não há gatos (negativo real). O modelo classificou 160 imagens como contendo gatos (classe "sim") e 40 como não contendo gatos (classe "não").
  - ✓ A matriz de confusão resultante (linhas = classe real; colunas = classe prevista) ficou.

	Predito: Gato	Predito: Não Gato	Total
Real: Gato	$\mathrm{TP} = 140$	$\mathrm{FN} = 30$	170
Real: Não Gato	$\mathrm{FP} = 20$	$\mathrm{TN} = 10$	30
Total	160	40	200

Machine Learning

Avaliação do modelo - Classificação

- **Exemplo**
  - ✓ A matriz de confusão resultante (linhas = classe real; colunas = classe prevista) ficou.
  - ✓ A partir disso, temos:
    - ✓ Precisão: $\frac{TP}{TP+FP} = \frac{140}{140+20} = 87{,}5\%$
    - ✓ Recall: $\frac{TP}{P} = \frac{140}{170} = 82{,}4\%$
    - ✓ F1-Score: $2\ x\ \frac{0.875\ x\ 0.824}{0.875+0.824} = 84{,}9\%$
    - ✓ Acurácia: $\frac{TP+TN}{P+N} = \frac{140+10}{170+30} = 75\%$
    - ✓ Taxa de Erro: $\frac{FP+FN}{P+N} = \frac{20+30}{200} = 25\%$

	Predito: Gato	Predito: Não Gato	Total
Real: Gato	TP = 140	FN = 30	170
Real: Não Gato	FP = 20	TN = 10	30
Total	160	40	200

Dúvidas?

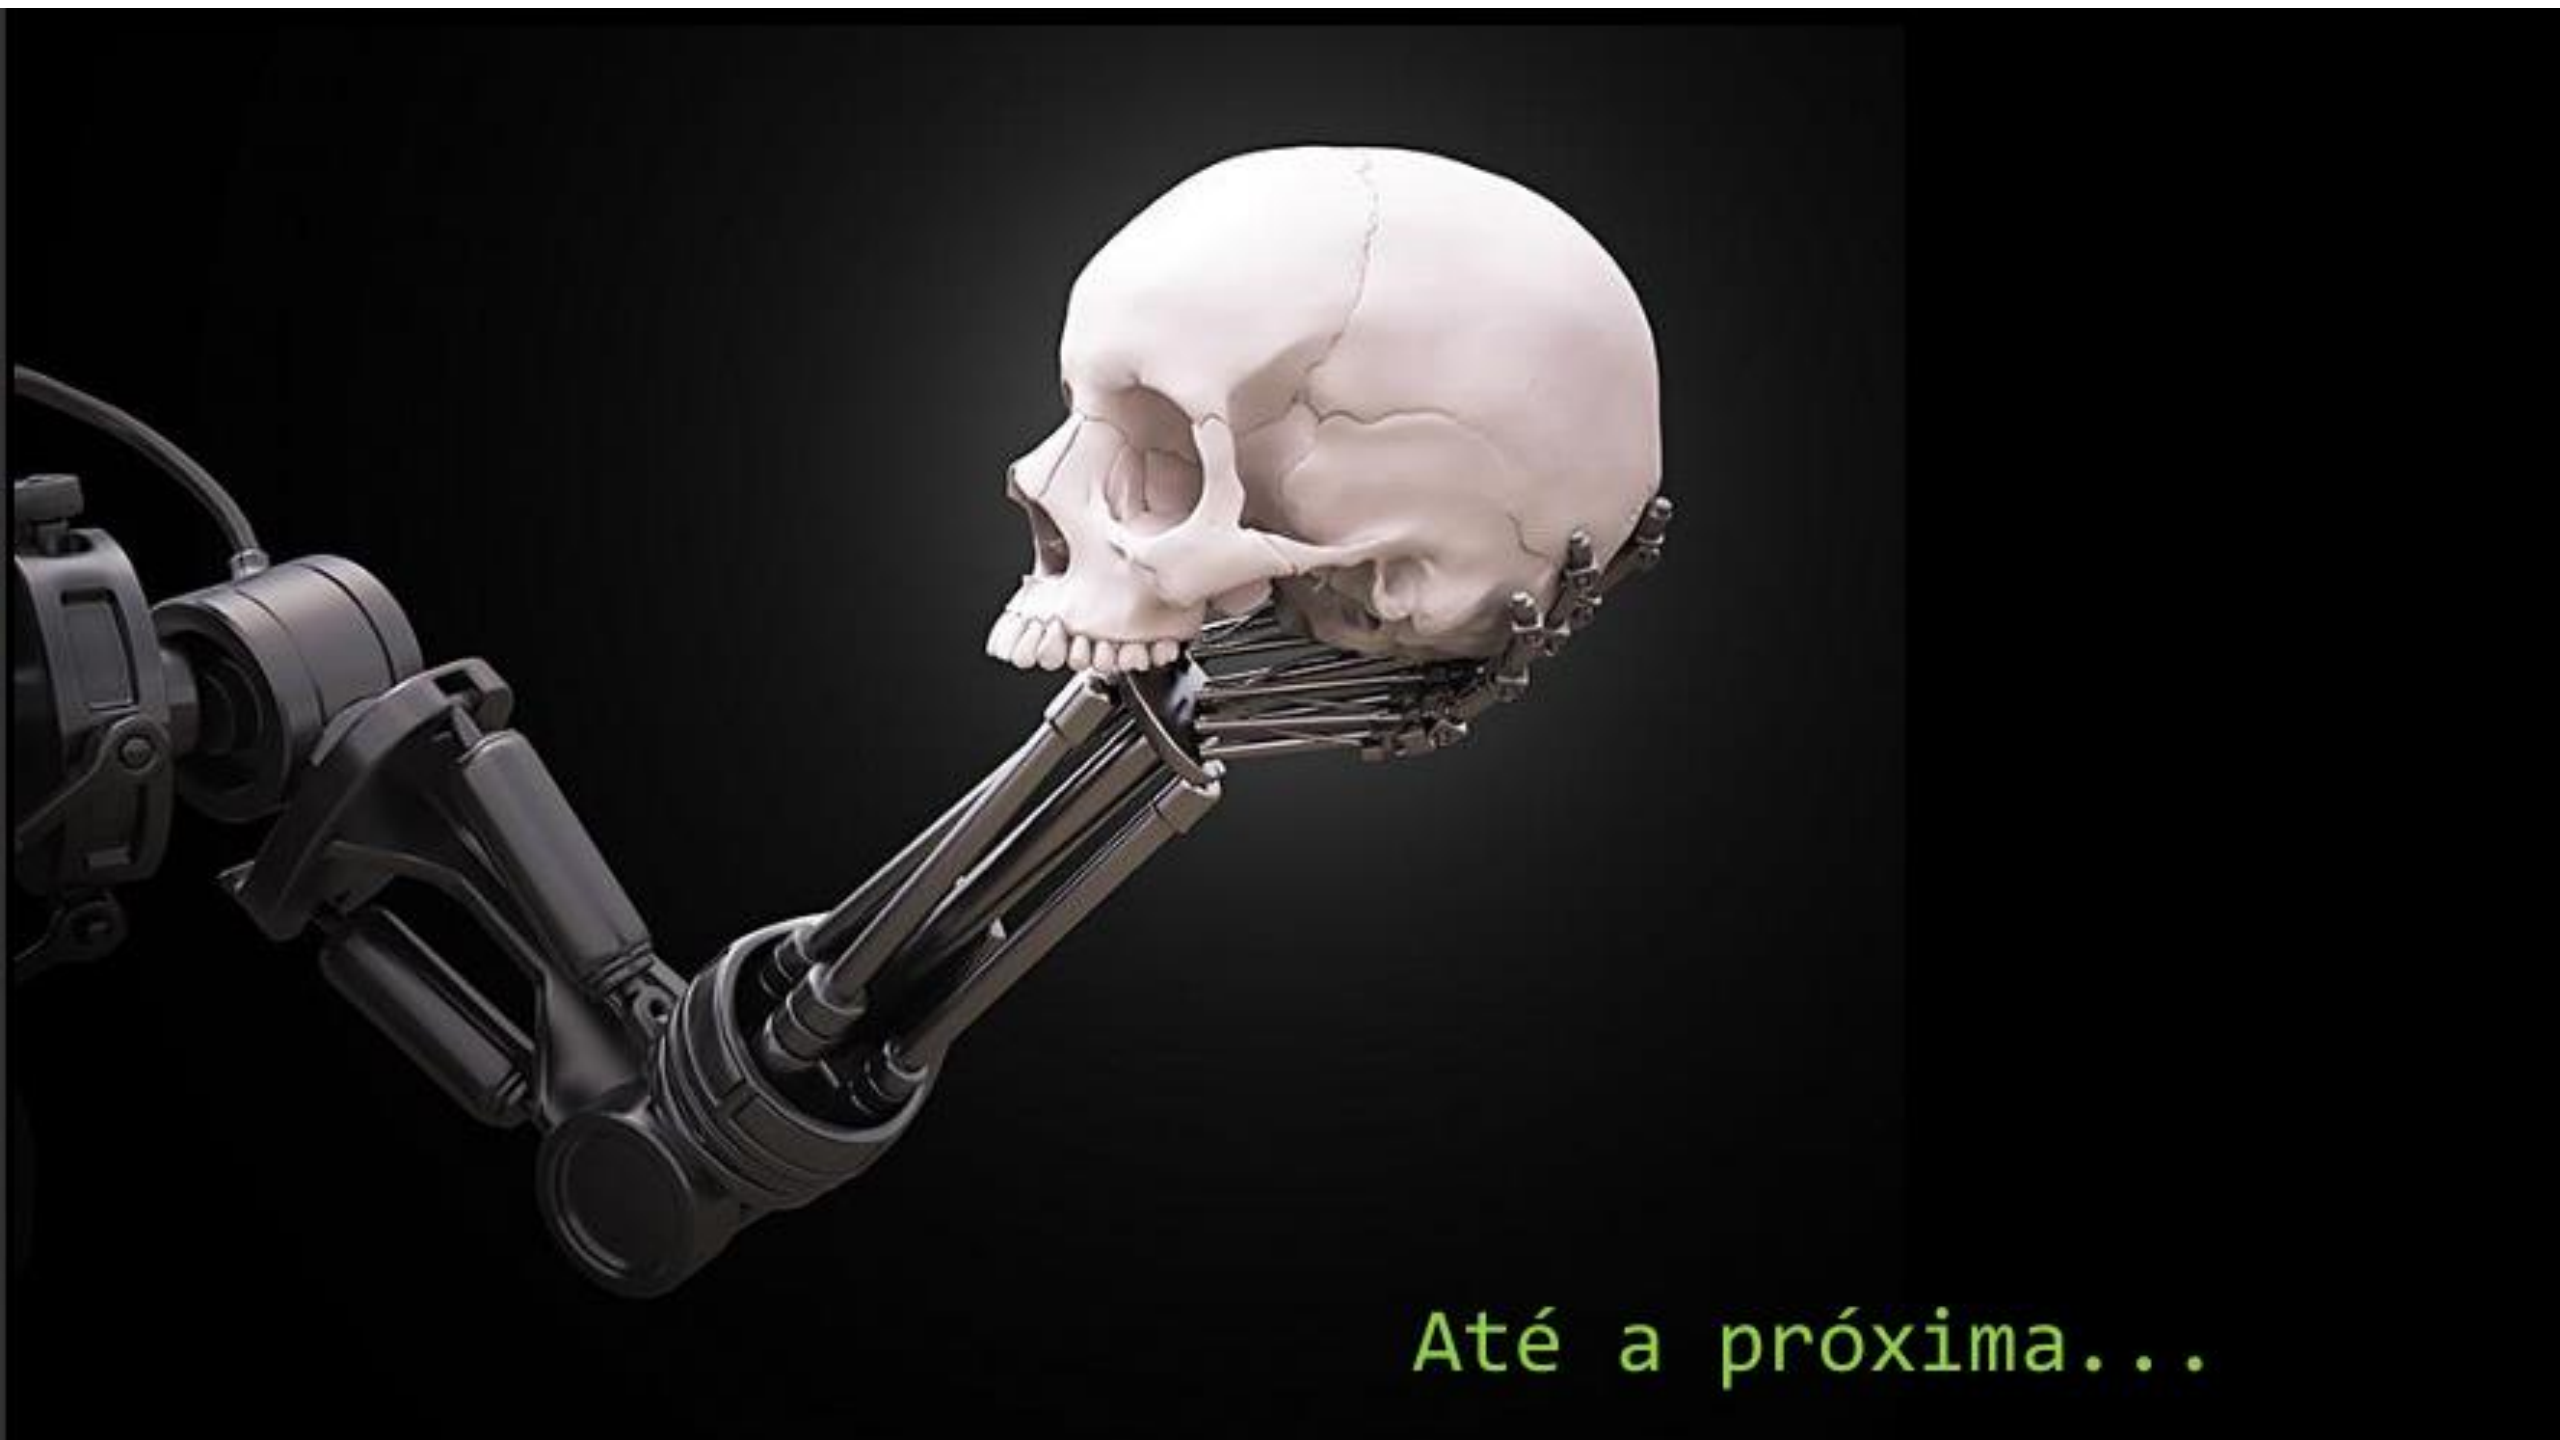
Até a próxima...

Apresentador

Thales Levi Azevedo Valente

E-mail:
thales.l.a.valente@gmail.com